Basic

1.Computer Vision

机器视觉（Computer Vision）是深度学习应用的主要方向之一。一般的CV问题包括以下三类：
Image Classification
Object detection
Neural Style Transfer

下图展示了一个神经风格转换（Neural Style Transfer）的例子：

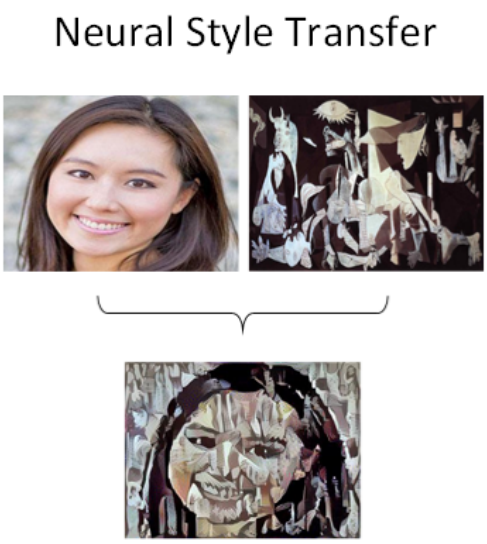

使用传统神经网络处理机器视觉的一个主要问题是输入层维度很大。
例如一张64x64x3的图片，神经网络输入层的维度为12288。如果图片尺寸较大，例如一张1000x1000x3的图片，神经网络输入层的维度将达到3百万，使得网络权重W非常庞大。
这样会造成两个后果，一是神经网络结构复杂，数据量相对不够，容易出现过拟合；二是所需内存、计算量较大。
解决这一问题的方法就是使用卷积神经网络（CNN）。

2. Edge Detection Example

对于CV问题，神经网络由浅层到深层，分别可以检测出图片的边缘特征 、局部特征（例如眼睛、鼻子等）、整体面部轮廓。

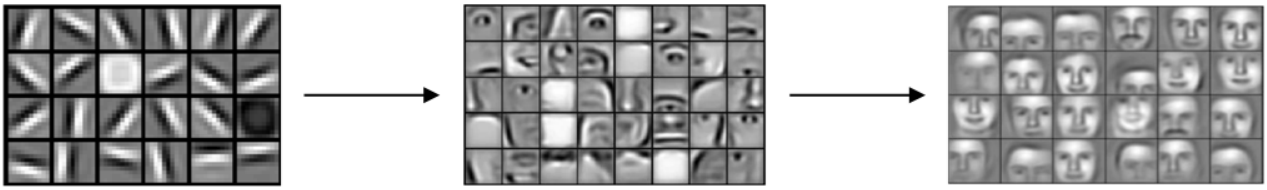

最常检测的图片边缘有两类：一是垂直边缘（vertical edges），二是水平边缘（horizontal edges）。

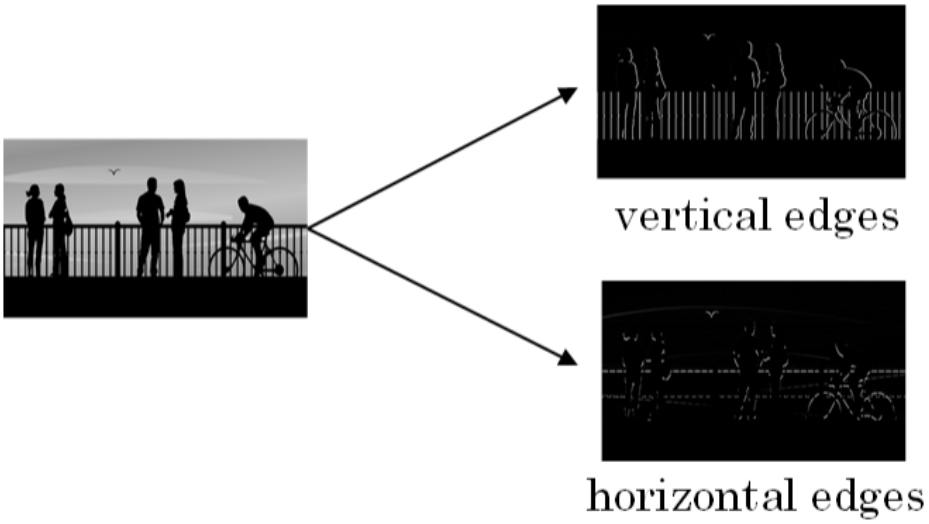

图片的边缘检测可以通过与相应滤波器进行卷积来实现。以垂直边缘检测为例，原始图片尺寸为6×6，滤波器filter尺寸为3×3，卷积后的图片尺寸为4×4，得到结果如下：

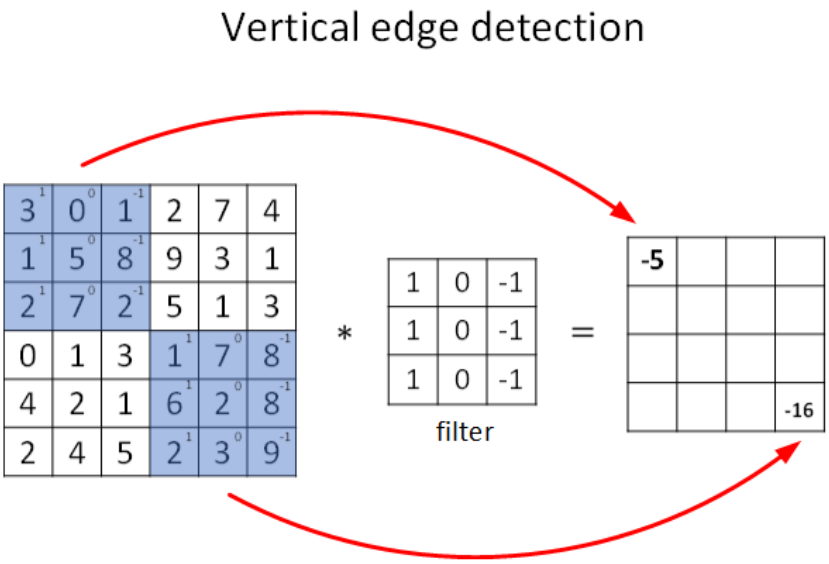

上图只显示了卷积后的第一个值和最后一个值。

*表示卷积操作。
python中，卷积用conv_forward()表示；tensorflow中，卷积用tf.nn.conv2d()表示；keras中，卷积用Conv2D()表示。

Vertical edge detection能够检测图片的垂直方向边缘。下图对应一个垂直边缘检测的例子：

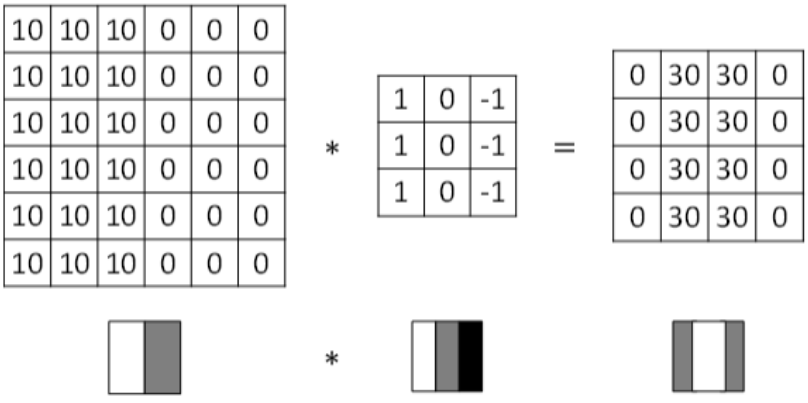

3.More Edge Detection

图片边缘有两种渐变方式，一种是**由明变暗**，另一种是**由暗变明。**
以垂直边缘检测为例，下图展示了两种方式的区别。
实际应用中，这两种渐变方式并不影响边缘检测结果，可以对输出图片取绝对值操作，得到同样的结果。

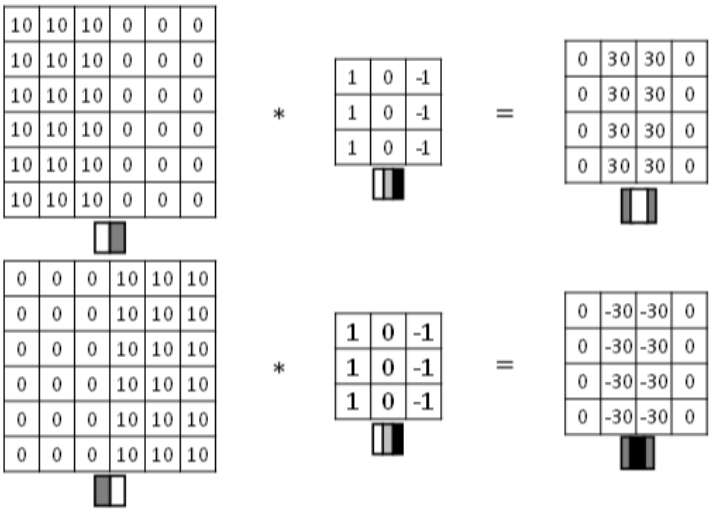

垂直边缘检测和水平边缘检测的滤波器算子如下所示：

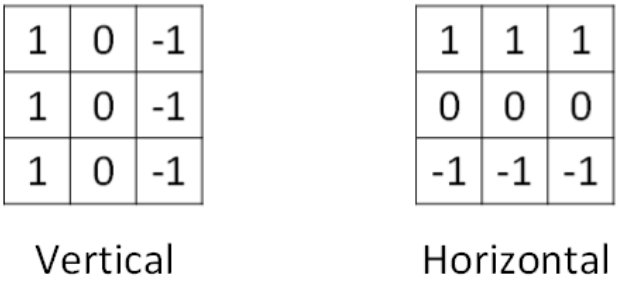

下图展示一个水平边缘检测的例子：

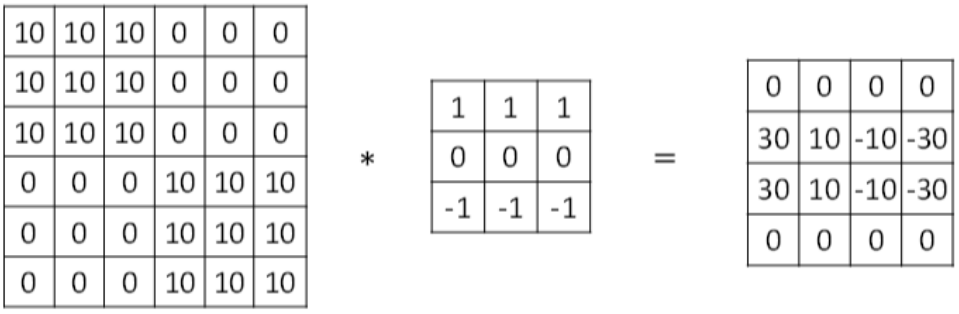

除了上面提到的这种简单的Vertical、Horizontal滤波器之外，还有其它常用的filters，例如**Sobel filter和Scharr filter。这两种滤波器的特点是增加图片中心区域的权重。**

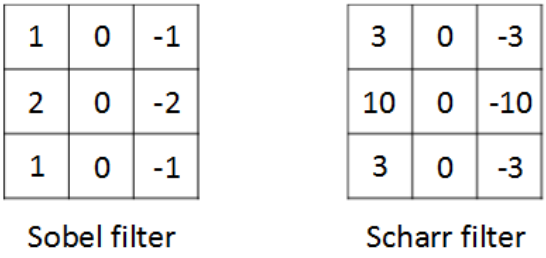

上图展示的是垂直边缘检测算子，水平边缘检测算子只需将上图顺时针翻转90度即可。

在深度学习中，如果想检测图片的各种边缘特征，而不仅限于垂直边缘和水平边缘，那么filter的数值一般需要通过模型训练得到，类似于标准神经网络中的权重W一样由梯度下降算法反复迭代求得。**CNN的主要目的就是计算出这些filter的数值。**确定得到了这些filter后，CNN浅层网络也就实现了对图片所有边缘特征的检测。

4. Padding

按照上面讲的图片卷积，如果原始图片尺寸为n x n，filter尺寸为f x f，则卷积后的图片尺寸为(n-f+1) x (n-f+1)，注意f一般为奇数。这样会带来两个问题：
1.卷积运算后，输出图片尺寸缩小
2.原始图片边缘信息对输出贡献得少，输出图片丢失边缘信息

为了解决图片缩小的问题，可以**使用padding方法，即把原始图片尺寸进行扩展，扩展区域补零**，用p来表示每个方向扩展的宽度。

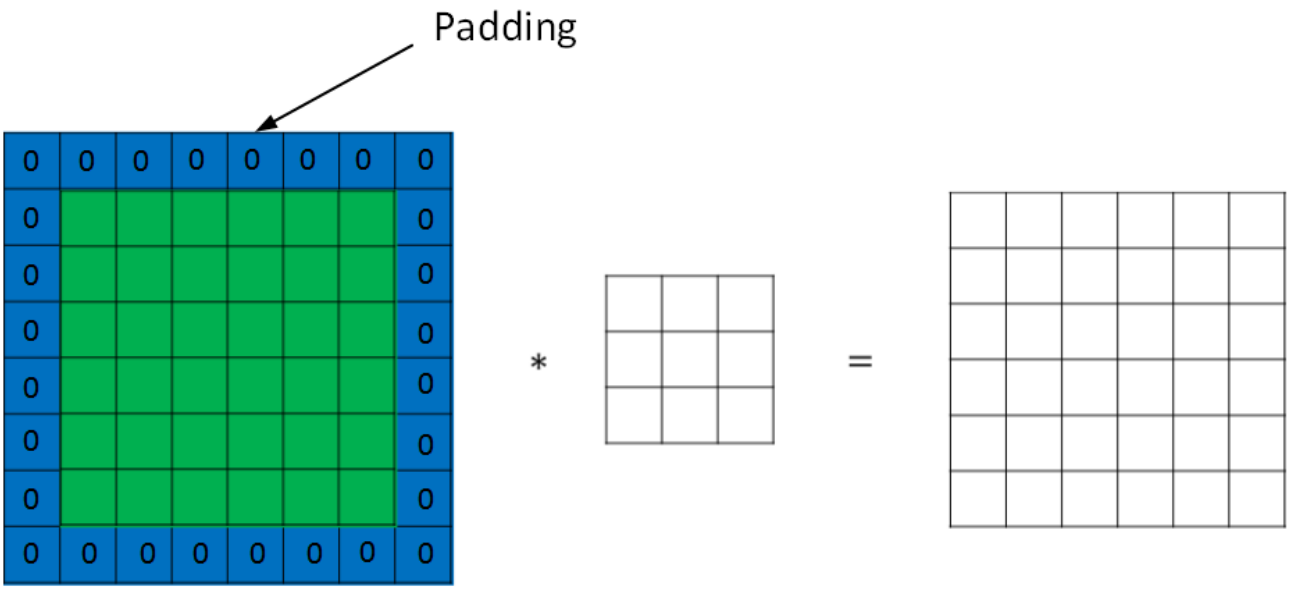

经过padding之后，原始图片尺寸为(n+2p) x (n+2p)，filter尺寸为f x f，则卷积后的图片尺寸为(n+2p-f+1) x (n+2p-f+1)。若要保证卷积前后图片尺寸不变，则p应满足：

$$p = \frac{f-1}{2}$$

没有padding操作，$p=0$，称之为“Valid convolutions”；有padding操作，$p=\frac{f-1}{2}$，称之为“Same convolutions”。

5. Strided Convolutions

Stride表示filter在原图片中水平方向和垂直方向每次的步进长度。之前默认stride=1。若stride=2，则表示filter每次步进长度为2，即隔一点移动一次。

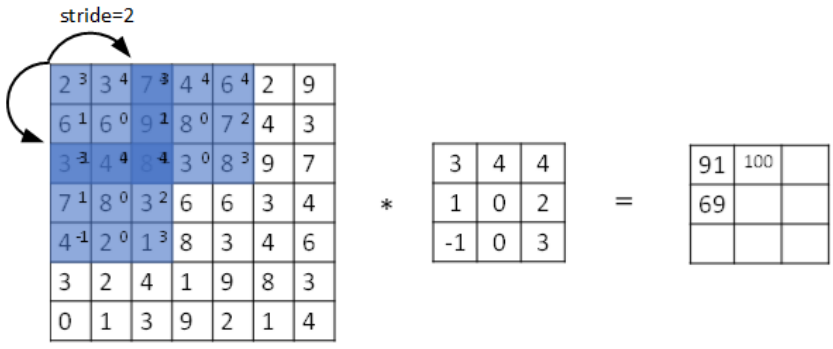

用s表示stride长度，p表示padding长度，如果原始图片尺寸为n x n，filter尺寸为f x f，则卷积后的图片尺寸为：

$$\lfloor \frac{n+2p-f}{s}+1 \rfloor \ X \ \lfloor \frac{n+2p-f}{s}+1 \rfloor$$

上式中，$\lfloor \cdots \rfloor$表示向下取整。

相关系数（cross-correlations）与卷积（convolutions）之间是有区别的。实际上，真正的卷积运算会先将filter绕其中心旋转180度，然后再将旋转后的filter在原始图片上进行滑动计算。filter旋转如下所示：

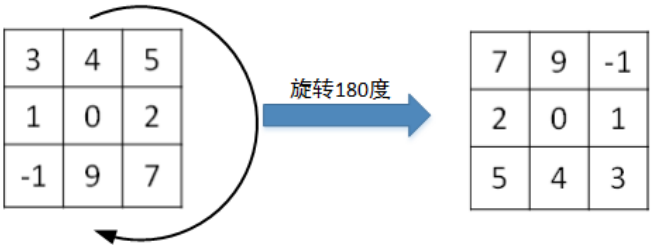

比较而言，相关系数的计算过程则不会对filter进行旋转，而是直接在原始图片上进行滑动计算。

其实，目前为止介绍的CNN卷积实际上计算的是相关系数，而不是数学意义上的卷积。但是，为了简化计算，一般把CNN中的这种“相关系数”就称作卷积运算。之所以可以这么等效，是因为滤波器算子一般是水平或垂直对称的，180度旋转影响不大；而且最终滤波器算子需要通过CNN网络梯度下降算法计算得到，旋转部分可以看作是包含在CNN模型算法中。总的来说，忽略旋转运算可以大大提高CNN网络运算速度，而且不影响模型性能。

卷积运算服从结合律：

$$(A * B) * C = A * (B * C)$$

6. Convolutions Over Volume

对于3通道的RGB图片，其对应的滤波器算子同样也是3通道的。例如一个图片是6 x 6 x 3，分别表示图片的高度（height）、宽度（weight）和通道（#channel）。

3通道图片的卷积运算与单通道图片的卷积运算基本一致。过程是将每个单通道（R，G，B）与对应的filter进行卷积运算求和，然后再将3通道的和相加，得到输出图片的一个像素值。

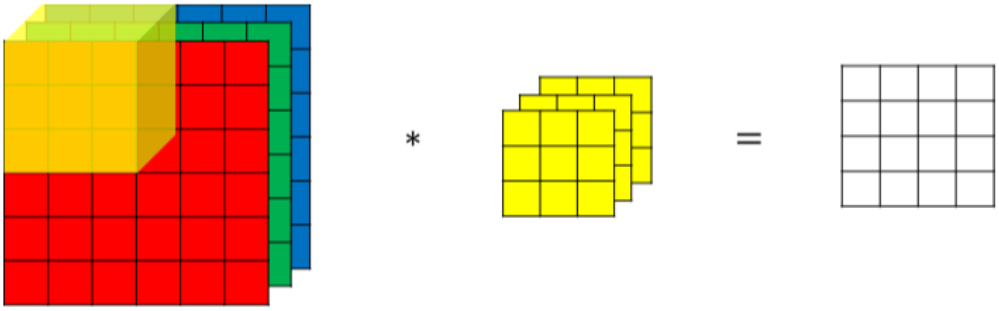

不同通道的滤波算子可以不相同。例如R通道filter实现垂直边缘检测，G和B通道不进行边缘检测，全部置零，或者将R，G，B三通道filter全部设置为水平边缘检测。

为了进行多个卷积运算，实现更多边缘检测，可以增加更多的滤波器组。例如设置第一个滤波器组实现垂直边缘检测，第二个滤波器组实现水平边缘检测。这样，不同滤波器组卷积得到不同的输出，个数由滤波器组决定。

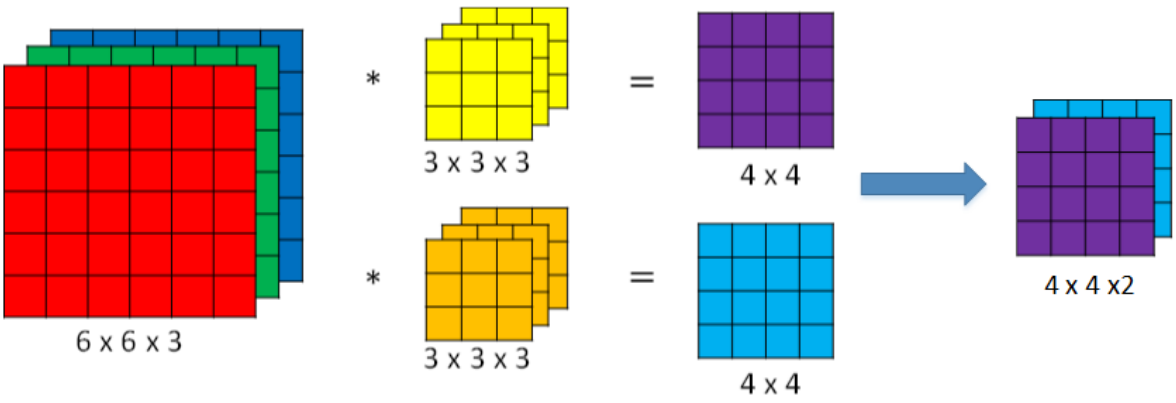

若输入图片的尺寸为$n * n * n_c$，filter尺寸为$f * f * n_c$，则卷积后的图片尺寸为$(n - f + 1) * (n - f + 1) * n_c'$。其中，$n_c$为图片通道数目，$n_c'$为滤波器组个数。

7. One Layer of a Convolutional Network

卷积神经网络的单层结构如下所示：

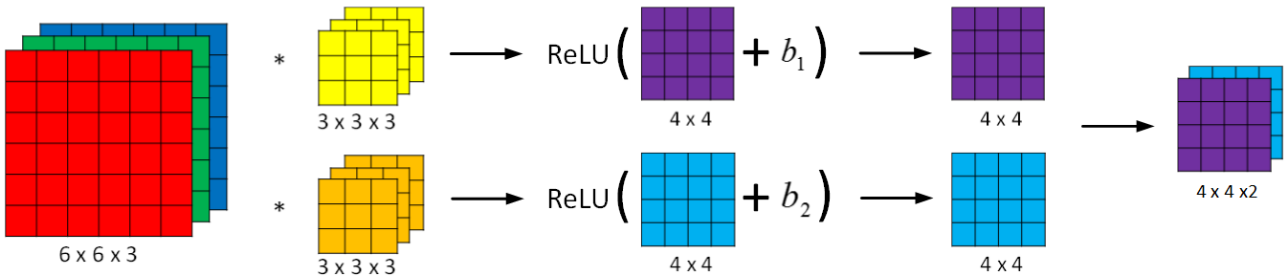

相比之前的卷积过程，CNN的单层结构多了激活函数ReLU和偏移量b。整个过程与标准的神经网络单层结构非常类似：

$$Z^{[l]} = W^{[l]}A^{[l-1]} + b$$

$$A^{[l]} = g^{[l]}(Z^{[l]})$$

卷积运算对应着上式中的乘积运算，滤波器组数值对应着权重$W^{[l]}$，所选的激活函数为ReLU。

计算一下上图中参数的数目：每个滤波器组有3x3x3=27个参数，还有1个偏移量b，则每个滤波器组有27+1=28个参数，两个滤波器组总共包含28×2=56个参数。发现，**选定滤波器组后，参数数目与输入图片尺寸无关。**所以，就不存在由于图片尺寸过大，造成参数过多的情况。例如一张1000x1000x3的图片，标准神经网络输入层的维度将达到3百万，而在CNN中，参数数目只由滤波器组决定，数目相对来说要少得多，这是CNN的优势之一。

最后，总结一下CNN单层结构的所有标记符号，设层数为l。

$$f^{[l]} = filtersize$$

$$p^{[l]} = padding$$

$$s^{[l]} = stride$$

$$n_c^{[l]} = numberoffilters$$

输入维度为：$n_H^{[l-1]}$ x $n_W^{[l-1]}$ x $n_c^{[l-1]}$

每个滤波器组维度为：$f^{[l]}$ x $f^{[l]}$ x $n_c^{[l-1]}$

权重维度为：$f^{[l]}$ x $f^{[l]}$ x $n_c^{[l-1]}$

偏置维度为：1 x 1 x 1 x $n_c^{[l]}$

输出维度为：$n_H^{[l]}$ x $n_W^{[l]}$ x $n_c^{[l]}$

其中，

$$n_H^{[l]} = \lfloor \frac{n_H^{[l-1]} + 2p^{[l]} - f^{[l]}}{s^{[l]}} + 1 \rfloor$$

$$n_W^{[l]} = \lfloor \frac{n_W^{[l-1]} + 2p^{[l]} - f^{[l]}}{s^{[l]}} + 1 \rfloor$$

如果有m个样本，进行向量化运算，相应的输出维度为：m x $n_H^{[l]}$ x $n_W^{[l]}$ x $n_c^{[l]}$

8. Simple Convolutional Network Example

下面介绍一个简单的CNN网络模型：

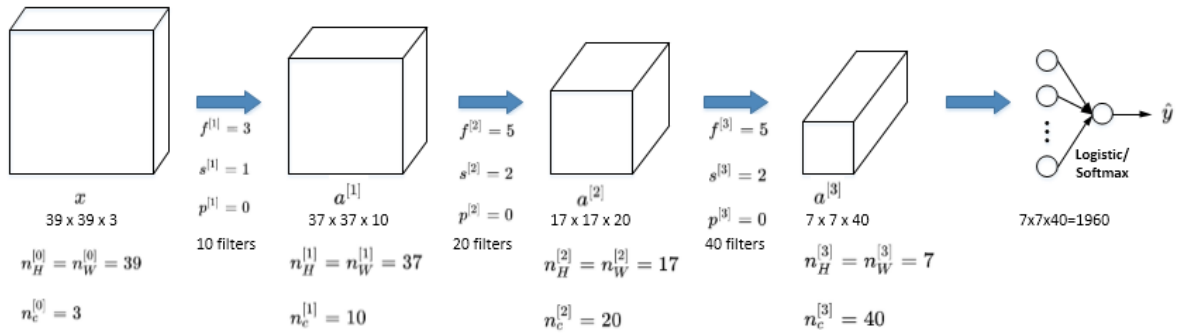

该CNN模型各层结构如上图所示。需要注意的是，$a^{[3]}$的维度是7 x 7 x 40，将$a^{[3]}$排列成1列，维度为1960 x 1，然后连接最后一级输出层。输出层可以是一个神经元，即二元分类（logistic）；也可以是多个神经元，即多元分类（softmax）。最后得到预测输出$\hat{y}$。

值得一提的是，随着CNN层数增加，$n_H^{[l]}$和$n_W^{[l]}$一般逐渐减小，而$n_c^{[l]}$一般逐渐增大。

CNN有三种类型的layer：
Convolution层（CONV）
Pooling层（POOL）
Fully connected层（FC）

CONV最为常见也最重要。

9. Pooling Layers

Pooling layers是CNN中用来减小尺寸，提高运算速度的，同样能减小noise影响，让各特征更具有健壮性。

Pooling layers的做法比convolution layers简单许多，没有卷积运算，**仅仅是在滤波器算子滑动区域内取最大值**，即max pooling，这是最常用的做法。注意，超参数p很少在pooling layers中使用。

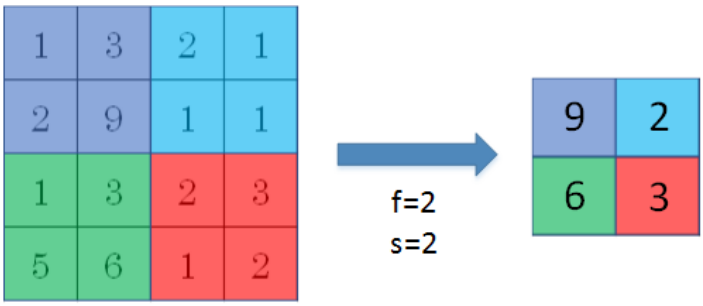

Max pooling的好处是只保留区域内的最大值（特征），忽略其它值，降低noise影响，提高模型健壮性。而且，max pooling需要的超参数仅为滤波器尺寸f和滤波器步进长度s，没有其他参数需要模型训练得到，计算量很小。

如果是多个通道，那么就每个通道单独进行max pooling操作。

除了max pooling之外，还有一种做法：average pooling。顾名思义，**average pooling就是在滤波器算子滑动区域计算平均值。**

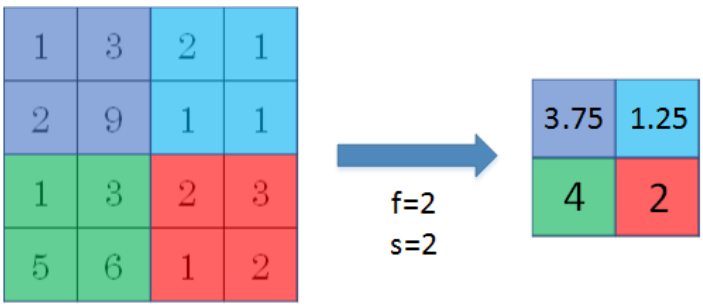

实际应用中，max pooling比average pooling更为常用。

10. CNN Example

下面介绍一个简单的数字识别的CNN例子：

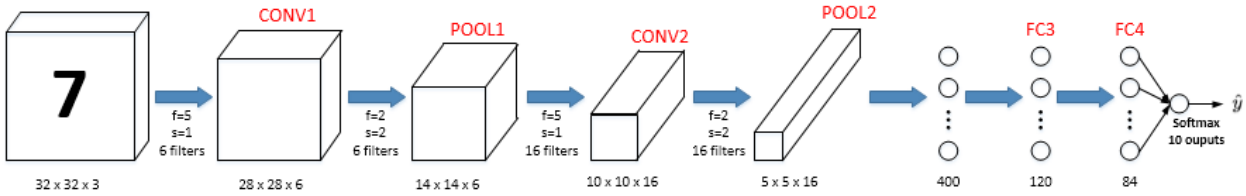

图中，CON层后面紧接一个POOL层，CONV1和POOL1构成第一层，CONV2和POOL2构成第二层。特别注意的是FC3和FC4为全连接层FC，它跟标准的神经网络结构一致。最后的输出层（softmax）由10个神经元构成。

整个网络各层的尺寸和参数如下表格所示：

	Activation shape	Activation Size	# parameters
Input:	(32,32,3)	3072	0
CONV1(f=5,s=1)	(28,28,6)	4704	158
POOL1	(14,14,6)	1176	0
CONV2(f=5,s=1)	(10,10,16)	1600	416
POOL2	(5,5,16)	400	0
FC3	(120,1)	120	48120
FC4	(84,1)	84	10164
Softmax	(10,1)	10	850

11. Why Convolutions

相比标准神经网络，CNN的优势之一就是参数数目要少得多。参数数目少的原因有两个：
1.参数共享：一个特征检测器（例如垂直边缘检测）对图片某块区域有用，同时也可能作用在图片其它区域。
2.连接的稀疏性：因为滤波器算子尺寸限制，每一层的每个输出只与输入部分区域内有关。

除此之外，由于CNN参数数目较小，所需的训练样本就相对较少，从而一定程度上不容易发生过拟合现象。而且，CNN比较擅长捕捉区域位置偏移。也就是说CNN进行物体检测时，不太受物体所处图片位置的影响，增加检测的准确性和系统的健壮性。